Минобрнауки России
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Волгоградский государственный технический университет»

Факультет Электроники и вычислительной техники

Кафедра Электронно-вычислительные машины и системы

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
к курсовой работе (проекту)

по дисциплине Системы обработки больших данных

на тему: Исследование датасета атмосферных осадков в Гонконге с использованием фреймворка Apache Spark

Студент Крутов Андрей Павлович
(фамилия, имя, отчество)

Группа ЭВМ-1.3

Руководитель работы (проекта) _____ П.Д. Кравченя
(подпись и дата подписания) (инициалы и фамилия)

Члены комиссии:

_____ _____
(подпись и дата подписания) (инициалы и фамилия)

_____ _____
(подпись и дата подписания) (инициалы и фамилия)

_____ _____
(подпись и дата подписания) (инициалы и фамилия)

Нормоконтроллер _____ П.Д. Кравченя
(подпись и дата подписания) (инициалы и фамилия)

Волгоград 2026

Минобрнауки России
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Волгоградский государственный технический университет»

Факультет Электроники и вычислительной техники

Направление (специальность) Информатика и вычислительная техника

Кафедра Электронно-вычислительные машины и системы

Дисциплина Системы обработки больших данных

Утверждаю
Зав. кафедрой А.Е. Андреев

«____» _____20 _____г.

ЗАДАНИЕ
на курсовую работу (проект)

Студент Крутов Андрей Павлович
(фамилия, имя, отчество)

Группа ЭВМ-1.3

1. Тема: Исследование датасета рыночный показателей видеоигр с использованием фреймворка Apache Spark

Утверждена приказом от «___» _____20 ___г., № _____.

2. Срок представления работы (проекта) к защите «___» _____20 ___г.

3. Содержание расчётно-пояснительной записки: РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ С ИСПОЛЬЗОВАНИЕМ PYSPARK; МАШИННОЕ ОБУЧЕНИЕ НА БОЛЬШИХ ДАННЫХ.

4. Перечень графического материала: _____

5. Дата выдачи задания «___» _____20 ___г.

Руководитель работы (проекта) _____ П.Д. Кравченя
(подпись и дата подписания) (инициалы и фамилия)

Задание принял к исполнению _____ А.П.Крутов
(подпись и дата подписания) (инициалы и фамилия)

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 4

1 РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ С ИСПОЛЬЗОВАНИЕМ PYSPARK 5

1.1 Постановка задачи разведочного анализа 5

1.2 Описание датасета 5

1.3 Определение пропущенных значений 6

1.4 Визуализация распределений признаков 6

1.5 Выводы 7

2 МАШИННОЕ ОБУЧЕНИЕ НА БОЛЬШИХ ДАННЫХ 8

2.1 Задача регресии 8

2.1.1 Постановка задачи регрессии 8

2.1.2 Решение задачи регрессии 8

2.1.3 Анализ полученных результатов 9

2.2 Задача бинарной классификации 9

2.2.1 Постановка задачи бинарной классификации 9

2.2.2 Решение задачи бинарной классификации 9

2.2.3 Анализ полученных результатов 11

2.3 Выводы 12

ЗАКЛЮЧЕНИЕ 13

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 14

ПРИЛОЖЕНИЕ А 15

ВВЕДЕНИЕ

Современная индустрия видеоигр представляет собой динамично развивающийся сектор развлечений с объемом рынка, исчисляющимся миллиардами долларов. Успех игры на рынке зависит от множества факторов: выбранной платформы, жанра, ценовой политики и маркетинговых усилий. В связи с этим особую актуальность приобретает задача прогнозирования коммерческого успеха игр на основе анализа больших данных (Big Data). Использование инструментов распределенных вычислений, таких как Apache Spark, позволяет эффективно обрабатывать миллионы записей и выявлять скрытые закономерности.

В связи с этим целью данной работы являлось обучение и валидация моделей машинного обучения (регрессии и бинарной классификации) для прогнозирования рыночных показателей видеоигр с использованием фреймворка Apache Spark.

Для достижения поставленной цели решались следующие задачи:

1. Провести разведочный анализ данных (EDA) и подготовить признаки для обучения;
2. Построить и обучить модель линейной регрессии для прогнозирования выручки игры;
3. Построить и обучить модель градиентного бустинга на деревьях решений для бинарной классификации (предсказания хита);
4. Проанализировать метрики качества обученных моделей и подобрать оптимальные гиперпараметры.

В первом разделе рассмотрена постановка задачи разведочного анализа, описание датасета и обработка пропущенных значений. Во втором разделе описано решение задач регрессии и бинарной классификации, формирование ML-конвейеров и анализ полученных результатов. В заключении сформулированы общие выводы по работе.

1 РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ С ИСПОЛЬЗОВАНИЕМ PYSPARK

1.1 Постановка задачи разведочного анализа

В рамках первой части работы был проведен разведочный анализ данных (EDA) с использованием PySpark. Задачей являлось исследование структуры датасета, выявление аномалий, обработка выбросов и сохранение очищенных данных в табличный формат Apache Iceberg для их дальнейшего использования в задачах машинного обучения.

1.2 Описание датасета

Для исследования был выбран датасет Video Game Market Price and Revenue Dataset (ссылка: https://www.kaggle.com/datasets/amith1707/video-game-market-price-and-revenue-dataset).

Датасет представляет собой симуляцию рыночных показателей видеоигр за период с 2019 по 2024 год. Объем данных составляет более 5.5 миллионов строк (около 4.7 ГБ в формате CSV). Каждая строка — это еженедельное наблюдение за конкретной игрой. Всего в датасете представлено около 10 000 уникальных игр на различных платформах (PC, PlayStation, Xbox, Nintendo Switch).

В таблице 1 приведено описание основных признаков, использованных в работе.

Таблица 1 – Описание ключевых признаков датасета

Признак	Расшифровка признака
game_id	Идентификатор игры
platform	Платформа (PC, PS5, Xbox, Switch)
genre	Жанр игры
current_price_usd	Текущая цена в USD
discount_pct	Процент скидки
concurrent_players	Одновременные игроки
review_count	Количество отзывов
steam_rating_pct	Рейтинг Steam (доля от 0 до 1)
hype_score	Индекс «хайпа» вокруг игры
estimated_revenue_usd	Оценка выручки в USD (целевая переменная)

1.3 Определение пропущенных значений

В ходе разведочного анализа была проведена проверка на наличие пропущенных значений (NULL) с использованием Spark DataFrame API. Проверка показала, что в выбранных для анализа 37 колонках пропущенные значения отсутствуют (0.00%). Это связано с тем, что датасет является синтетически сгенерированным.

Также были проанализированы количественные признаки. Для признака days_since_release были выявлены выбросы (значения больше 2190 дней, что превышает 6-летний период датасета). Эти выбросы были ограничены максимальным значением 2190.

1.4 Визуализация распределений признаков

Для визуального анализа распределения количественных признаков в

PySpark использовались агрегация данных и последующее построение графиков с помощью библиотеки Seaborn. Поскольку исходный датафрейм содержит миллионы строк, данные предварительно группировались по бинам (интервалам) прямо в Spark, и только затем переносились в память драйвера для отрисовки.

Ниже приведен фрагмент кода, реализующий построение гистограммы распределения (в качестве примера взят признак estimated_units_sold):

```
import seaborn as sns
import matplotlib.pyplot as plt
from pyspark.sql.functions import col, floor
def plot_quant_distribution(data, column, num_bins=200):
min_value = data.agg({column: "min"}).collect()[0][0]
    max_value = data.agg({column: "max"}).collect()[0][0]
    bin_size = (max_value - min_value) / num_bins
    data = data.withColumn("bin", floor((col(column) - min_value) / bin_size))
bin_counts = data.groupBy("bin").count()
bin_counts_pd = bin_counts.limit(1000).toPandas()
plt.figure(figsize=(15, 5))
sns.histplot(data=bin_counts_pd, x="bin", weights="count", kde=True)
plt.title(f"Распределение признака {column}")
plt.show()plot_quant_distribution(data=df, column="estimated_units_sold")
```

1.5 Выводы

В ходе разведочного анализа был успешно обработан датасет объемом 4.7 ГБ. Данные были очищены от выбросов, приведены к корректным типам и сохранены в таблицу sobd_lab1_processed_table. Анализ показал сильный дисбаланс в сторону «бестселлеров» и выявил сильные корреляции между показателями вовлеченности игроков и коммерческим успехом.

2 МАШИННОЕ ОБУЧЕНИЕ НА БОЛЬШИХ ДАННЫХ

В данной главе описано решение двух задач машинного обучения с использованием библиотеки SparkML: задачи регрессии (прогнозирование суммы выручки) и задачи бинарной классификации (определение того, станет ли игра хитом).

2.1 Задача регресии

2.1.1 Постановка задачи регрессии

Требуется построить модель линейной регрессии (LinearRegression), которая на основе признаков (цена, платформа, жанр, количество отзывов, рейтинги и т.д.) будет предсказывать целевую переменную — оценку выручки игры (estimated_revenue_usd) в долларах США. Для оценки качества модели используются метрики RMSE (среднеквадратичная ошибка) и R^2 (коэффициент детерминации).

2.1.2 Решение задачи регрессии

Для решения задачи был сформирован ML-конвейер (Pipeline), включающий следующие этапы:

Кодирование категориальных признаков: для колонок platform, storefront, genre и др. были применены StringIndexer (преобразование строк в числовые индексы) и OneHotEncoder (создание бинарных векторов).

Масштабирование числовых признаков: для колонок current_price_usd, review_count и др. был применен MinMaxScaler для приведения значений к диапазону [0, 1].

Сборка вектора признаков: VectorAssembler объединил все признаки в один вектор features.

Обучение модели: LinearRegression с подбором гиперпараметров

(regParam, elasticNetParam) с помощью CrossValidator (кросс-валидация).

2.1.3 Анализ полученных результатов

После обучения модели на 80% данных и проверки на 20% тестовой выборке были получены следующие метрики: RMSE (Root Mean Squared Error): 33 587 917.55 R^2 (R-squared): 0.78 Интерпретация: Значение $R^2 = 0.78$ означает, что модель объясняет 78% дисперсии целевой переменной. Это отличный показатель для линейной модели. Значение RMSE в 33.5 млн долларов обусловлено наличием крупных выбросов (мега-хитов), выручка которых достигает сотен миллионов, что вносит большой вклад в квадратичную ошибку. Тем не менее, модель хорошо улавливает общие тренды.

2.2 Задача бинарной классификации

2.2.1 Постановка задачи бинарной классификации

В датасете отсутствовал готовый бинарный признак, поэтому он был создан искусственно. Целевой переменной стал признак is_hit, полученный путем бинаризации колонки hype_score: если индекс хайпа был больше 50, игра считалась хитом (1.0), иначе — нет (0.0).

Требуется обучить модель градиентного бустинга на деревьях решений (GBTClassifier) для предсказания этого факта. Оценка качества проводится с помощью метрик Precision (точность), Recall (полнота), F1-меры и AUC-ROC.

2.2.2 Решение задачи бинарной классификации

Исходный датасет обладал сильным дисбалансом классов: на 4 290 857 «не-хитов» приходилось всего 176 379 «хитов» (около 4%). Обучение на таких данных привело бы к тому, что модель всегда предсказывала бы класс 0.

Для решения этой проблемы был применен

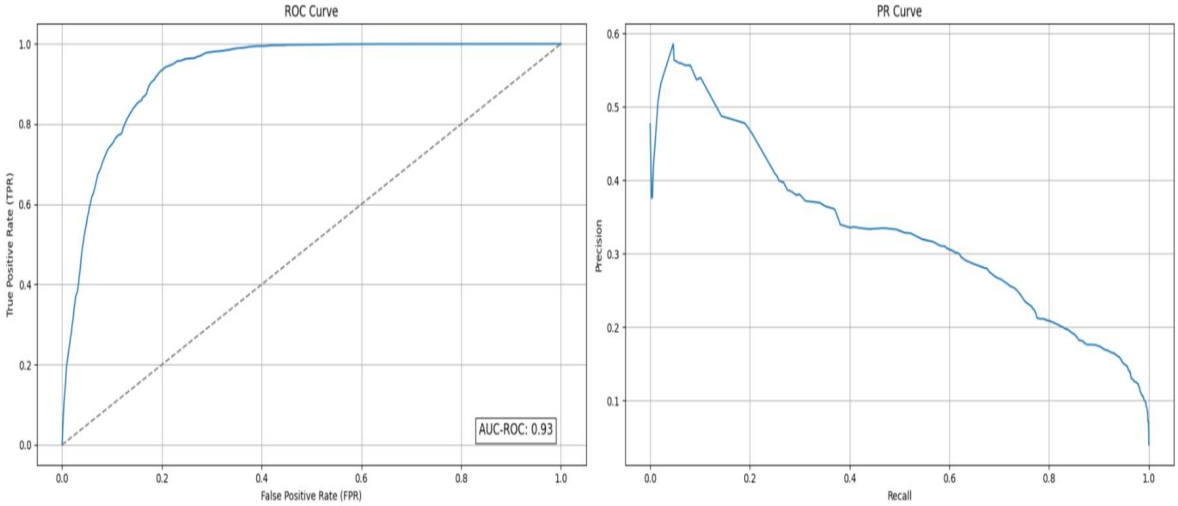
метод oversampling (искусственное увеличение количества объектов миноритарного класса). После балансировки количество классов в обучающей выборке стало примерно равным (около 4.2 млн каждого).

Далее был построен конвейер, включающий StringIndexer для категорий, VectorAssembler для сборки признаков (числовые признаки для деревьев не требуют масштабирования) и саму модель GBTClassifier. Гиперпараметры подбирались через CrossValidator.

2.2.3 Анализ полученных результатов

После обучения модели были получены графики ROC-кривой и PR-кривой.

Рисунок 1 – ROC-кривая и PR-кривая модели классификации



Значение AUC-ROC составило 0.93, что свидетельствует о высокой способности модели разделять классы. ROC-кривая имеет выраженную выпуклую форму, приближаясь к левому верхнему углу, что подтверждает высокое качество ранжирования объектов.

При стандартном пороге вероятности (0.5) модель показала высокую полноту (Recall = 94.5%), но низкую точность (Precision = 15.4%), что означает склонность модели к ложноположительным срабатываниям.

В соответствии с заданием был подобран оптимальный порог вероятности (0.81), при котором полнота (Recall) удерживается на уровне не менее 60%. Результаты на тестовой выборке после подбора порога:

Precision: 0.3056 (30.5%)

Recall: 0.5992 (59.9%)

F1-мера: 0.4048 (40.4%)

Интерпретация: Снизив количество ложных срабатываний (повысив порог), мы увеличили точность предсказания хитов в два раза (с 15% до 30%), при этом пожертвовали частью полноты, удержав её на требуемом уровне 60%. Это демонстрирует классический компромисс между Precision и Recall в

задачах с несбалансированными классами.

2.3 Выводы

В ходе выполнения второй главы были обучены две модели машинного обучения на большом объеме данных.

Модель линейной регрессии показала высокое качество ($R^2 = 0.78$), что позволяет использовать её для приблизительной оценки коммерческого потенциала игры.

Модель градиентного бустинга показала отличный показатель AUC-ROC (0.93). Благодаря проведению oversampling и подбору порога вероятности, модель способна находить 60% потенциальных хитов, при этом точность предсказания составляет около 30%.

ЗАКЛЮЧЕНИЕ

В ходе курсовой работы были освоены методы обработки больших данных с использованием экосистемы Apache Hadoop (HDFS, YARN) и фреймворка Apache Spark (PySpark, SparkML).

Был проведен полный цикл анализа данных: от загрузки сырого файла объемом 4.7 ГБ в HDFS до обучения и валидации моделей машинного обучения. В ходе работы были решены задачи регрессии (прогнозирование выручки) и бинарной классификации (прогнозирование хита).

Практическая значимость работы заключается в том, что построенные модели позволяют автоматизировать оценку рыночного потенциала видеоигр на основе исторических данных об их цене, отзывах и вовлеченности игроков.

Дальнейшим направлением развития темы может стать использование более сложных архитектур (например, нейронных сетей), а также добавление текстовых признаков (анализ описаний и отзывов игроков) для повышения качества классификации.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Изучаем Spark: молниеносный анализ данных / Х. Карау [и др.]. — ДМК Пресс, 2015. — 304 с. — ил.
2. Exploratory Data Analysis with pySpark. — 2020. — URL: https://github.com/roshankoirala/pySpark_tutorial/blob/master/Exploratory_data_analysis_with_pySpark.ipynb ; Дата обращения: 19.09.2022.
3. *Уайт Т.* Hadoop: Подробное руководство. — 3-е изд. — СПб. : Питер, 2013. — 672 с. — ил.
4. *Tekdogan T.*, *Cakmak A.* Benchmarking Apache Spark and Hadoop MapReduce on Big Data Classification // ICCBDC 2021. Association for Computing Machinery, New York, NY, USA, pages 15-20 (2021). — 2022. — 21 сент. — С. 15—20. — (ICCBDC 2021). — DOI: 10.1145/3481646.3481649. — arXiv: 2209.10637 [cs.DC].
5. Официальный сайт Apache Spark. — 2022. — URL: https://spark.apache.org/ ; Дата обращения: 19.09.2022.
6. Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics / М. Захария [и др.] // Conference on Innovative Data Systems Research. — 2021. — URL: https://www.cidrdb.org/cidr2021/papers/cidr2021_paper17.pdf ; Дата обращения: 12.09.2024.

ПРИЛОЖЕНИЕ А

Пример листинга программного кода

```
import os
from pyspark.sql import SparkSession
from pyspark import SparkConf
def create_spark_configuration() -> SparkConf:
    user_name = os.getenv("USER")
    conf = SparkConf()
    conf.setAppName("lab 2 Test")
    conf.setMaster("yarn")
    return conf
conf = create_spark_configuration()
spark = SparkSession.builder.config(conf=conf).getOrCreate()
spark.catalog.setCurrentDatabase("krutov_database")
df = spark.table("sobd_lab1_processed_table")
```